



Prédiction de l'évolution de forces
d'emboutissage par étude des séries
temporelles
BachelorArbeit

Alexandre SIGIRIDIS-SCHLEPP

Sous la direction de
Tudor BALAN, Sandra CHEVRET, Wahb ZOUHRI, Ghinwa
OUAIDAT

Arts et métiers,
Campus de Metz

2023-2024

Remerciements

Je tiens à exprimer ma gratitude envers Monsieur Wahb ZOUHRI pour son aide très précieuse tout au long de mon Bachelorarbeit. Il a su m'aiguiller grâce à son encadrement attentif tout au long de ce Bachelorarbeit. Sa présence et son soutien ont largement contribué à enrichir mon étude sur la prédiction des séries temporelles.

Je souhaite exprimer ma profonde gratitude envers Balan TUDOR, Sandra CHEVRET et Ghinwa OUAIDAT. Leur contribution m'a permis d'étudier un sujet aussi captivant à explorer. Je les remercie chaleureusement pour les données précieuses qu'ils m'ont fournies, lesquelles ont servi de fondement solide à mon étude.

Table des matières

1	État de l'art	1
1.1	Formage incrémental robotisé	1
1.1.1	Introduction au procédé de formage incrémental robotisé	1
1.1.2	Pièce obtenue à partir du procédé de formage incrémental robotisé	2
1.1.3	Avantages et inconvénients du procédé de formage incrémental robotisé	3
1.2	Séries temporelles	3
1.2.1	Introduction des séries temporelles dans le cadre du Bachelorarbeit	3
1.2.2	Introduction à l'étude des séries temporelles	4
1.3	Prédiction des séries temporelles	7
1.3.1	Méthodes statistiques de prédiction des séries temporelles	7
1.3.2	Régression	8
1.3.3	Modèle à moyenne mobile (MA)	9
1.3.4	Modèle à régression autorégressive (AR)	10
1.3.5	Modèle ARIMA	10
1.3.6	Ordre du modèle ARIMA	11
1.3.7	Coefficients autorégressifs et de moyenne mobile	12
1.3.8	Machine learning	13
1.4	Choix du modèle	15
2	Travaux réalisés pour le Bachelorarbeit	16
2.1	Extraction des données	16
2.2	Mise en place d'un modèle ARIMA	17
2.3	Echantillonnage des séries temporelles de notre étude	18
2.3.1	Méthode d'échantillonnage	18
2.3.2	Vérification de la méthode d'échantillonnage	20
2.4	Prédiction des séries temporelles échantillonnées	20
2.4.1	Modèle ARIMA avec des hyperparamètres quelconques	20
2.4.2	Recherche des hyperparamètres optimaux pour le modèle ARIMA	22
2.5	Mise en place d'un modèle à moyenne pondérée	25
2.5.1	Conclusion	27

Résumé

In dieser Bachelorarbeit werden wir die Entwicklung der Formkraft eines robotergestützten inkrementellen Umformverfahrens eingehend untersuchen. Der Schwerpunkt dieser Arbeit liegt auf der Vorhersage der Formkraftentwicklung anhand von Zeitreihen, die den Verlauf der Formkraft im Zeitablauf dokumentieren.

Im ersten Teil der Arbeit werden wir einen umfassenden Überblick über den aktuellen Stand der Technik geben. Dazu gehört zunächst eine detaillierte Untersuchung des robotergestützten inkrementellen Umformverfahrens. Besonders berücksichtigt werden die Kräfte, die während des Umformprozesses wirken, und vor allem, wie diese Kräfte analysiert werden.

Anschließend werden wir uns mit Methoden zur Vorhersage von Zeitreihen beschäftigen. Zeitreihenanalyse ist ein wichtiger Bereich in der Statistik und maschinellem Lernen, der es ermöglicht, zukünftige Werte einer Serie basierend auf ihren historischen Daten vorherzusagen. Wir werden verschiedene Methoden und Modelle vorstellen, die in der Literatur zur Vorhersage von Zeitreihen verwendet werden, wie zum Beispiel einfache lineare Modelle, autoregressive Modelle (AR), integrierte autoregressive Modelle (ARIMA), sowie fortgeschrittene Techniken des maschinellen Lernens wie neuronale Netze.

Auf Basis des theoretischen Hintergrunds und der Literaturübersicht werden wir eine geeignete Vorhersagemethode auswählen, die wir dann auf unsere Daten anwenden. Wir werden die ausgewählte Methode implementieren und die Modellparameter so optimieren, dass die Vorhersagegenauigkeit maximiert wird.

Im zweiten Teil der Arbeit präsentieren wir die Ergebnisse unserer Vorhersagen. Wir werden die Genauigkeit und Zuverlässigkeit unseres Modells anhand verschiedener Metriken bewerten und die Vorhersagen mit den tatsächlichen gemessenen Werten vergleichen. Dabei werden wir auch die Herausforderungen und Probleme, die während der Modellierung und Implementierung aufgetreten sind, diskutieren.

Abschließend ziehen wir ein Fazit über die Leistungsfähigkeit der angewandten Methode und geben einen Ausblick auf mögliche zukünftige Arbeiten und Verbesserungen, die auf den Erkenntnissen dieser Bachelorarbeit aufbauen können.

Chapitre 1

État de l'art

1.1 Formage incrémental robotisé

1.1.1 Introduction au procédé de formage incrémental robotisé

La mise en forme des tôles est un axe de recherche important dans de nombreux domaines nécessitant l'utilisation de tôle, tel que l'industrie automobile, l'aéronautique, la construction navale, l'industrie métallurgique ou encore l'industrie électrique. C'est la raison pour laquelle il existe de nombreux procédés de mise en forme des tôles. Un des procédés les plus répandus est l'emboutissage. Ce procédé nécessite pour produire des pièces un outillage important, composé d'une matrice et d'un poinçon, qui sont propre à chaque pièce qu'on veut réaliser. C'est donc dans le cadre de pièces de petite série que s'inscrit le procédé de formage incrémental robotisé. Le principe du formage incrémental est de simplement déformer localement et successivement une tôle, en pilotant un poinçon de faible diamètre comparativement aux dimensions caractéristiques de celle-ci, jusqu'à obtenir la forme désirée.




FIGURE 1.1 – Schéma paramétré du procédé de formage incrémental robotisé [1]

Il existe différents types de formage incrémental robotisé, le formage mono-point et multi-points. Dans notre cadre, nous allons nous intéresser uniquement au formage mono-

point, car c'est celui-ci qui est présent dans l'atelier de l'ENSAM Metz, c'est-à-dire, le formage utilisant seulement un unique poinçon et aucune matrice qui permettrait de mettre en forme la tôle.




FIGURE 1.2 – Schéma du procédé de formage incrémental robotisé [1]

Ce procédé nécessite, comme dit précédemment, un poinçon, mais aussi un serre-flan et une matrice. Le principe du procédé de formage incrémental est basé sur le déplacement de l'outil appelé le poinçon, dont la trajectoire est pilotée par une machine à commande numérique ou un robot pour déformer localement la tôle immobilisée à ses extrémités par le serre-flan. Le poinçon peut être piloté en utilisant deux différentes trajectoires, une trajectoire par niveau et une trajectoire en spirale.




FIGURE 1.3 – Schéma de trajectoire en spirale [3]




FIGURE 1.4 – Schéma de trajectoires par niveau [3]

1.1.2 Pièce obtenue à partir du procédé de formage incrémental robotisé

Ce procédé peut être utilisé pour de nombreuses mises en forme différentes de tôles et permet de réaliser des pièces à géométrie complexe. Ce procédé a permis la mise en forme de tôles pour créer une prothèse de cheville, un implant crânien, ou encore un capot de voiture.



FIGURE 1.5 – Implant crânien obtenu par formage incrémental robotisé [3]

Ce procédé s'adapte à différents matériaux, l'aluminium, le cuivre, les aciers ou encore le titane. Cependant, dû aux efforts importants nécessaires lors de la mise en forme des tôles, le matériau principalement utilisé reste l'aluminium, pour diminuer l'effort requis.

1.1.3 Avantages et inconvénients du procédé de formage incrémental robotisé

Ce procédé possède de nombreux avantages comparés aux procédés de mise en forme des tôles plus classiques comme l'emboutissage. On peut citer comme avantage la flexibilité. En effet, dû à l'utilisation d'un poinçon de faible diamètre qui déforme localement la tôle, et de manière progressive, en utilisant un unique poinçon, nous pouvons réaliser de nombreuses pièces différentes. Ce procédé permet aussi de réduire les coûts de production, car il n'utilise pas de contre moules de formes spécifiques, les outillages sont simples et peu coûteux. De plus, nous pouvons aussi réaliser grâce à ce procédé, des pièces de grande taille et de formes asymétriques.

1.2 Séries temporelles

1.2.1 Introduction des séries temporelles dans le cadre du Bachelorarbeit

Le Bachelorarbeit FORECAST a pour but de prédire certaines évolutions de la force axiale nécessaire pour réaliser le formage. Cette force est exprimée comme une série temporelle. La définition de série temporelle est une suite de valeurs numériques représentant l'évolution d'une quantité spécifique au cours du temps. Chaque observation dans la série est associée à un moment spécifique, ce qui permet d'analyser et de comprendre les tendances, les motifs et les fluctuations qui peuvent se produire au fil du temps.




FIGURE 1.6 – Résultats expérimentaux de l'évolution de la force de formage [4]

Comme nous le montre la figure 6, l'évolution de la force de formage se décrit par une série temporelle, et celle-ci varie, suivant la configuration expérimentale. Dans le cadre du Bachelorarbeit, l'objectif est de prédire cette évolution de force suivant deux approches. La première approche serait la suivante : en connaissant l'évolution de la force jusqu'à un instant T , prédire la suite de l'évolution de la force (Figure 7). La seconde approche serait, à partir d'une base de données de résultats expérimentaux pour différentes configurations expérimentales, il faudrait prédire le résultat d'une nouvelle configuration (Figure 8).



FIGURE 1.7 – Prédiction après l'instant T [4]

FIGURE 1.8 – Prédiction d'une nouvelle configuration [4]

1.2.2 Introduction à l'étude des séries temporelles

L'étude des séries temporelles est un domaine de l'analyse des données qui porte sur l'analyse, la modélisation et la prédiction de données chronologiques. La compréhension des modèles, des tendances et des comportements qui se manifestent dans ces séries temporelles permet d'obtenir des connaissances précieuses pour la prise de décisions, la prévision

et la planification. Cette discipline trouve des applications dans de nombreux domaines tels que la finance, mais encore dans l'ingénierie. En utilisant des méthodes statistiques, mathématiques et informatiques, l'analyse des séries temporelles offre des outils puissants pour extraire des connaissances exploitables à partir de données temporelles. Il existe de nombreuses branches dans l'étude des séries temporelles, et ces branches vont être détaillées ci-dessous.

Prédiction

Soit X une série temporelle $X = x_1, x_2, \dots, x_N$ contenant N points, il s'agit de prédire la ou les valeurs suivantes (x_{N+1})




FIGURE 1.9 – Prédiction de séries temporelles [5]

Segmentation

Soit X une série temporelle X sur un intervalle I , il s'agit de rétrécir l'intervalle I tout en gardant une série temporelle similaire

Complétion

Soit X une série temporelle $X = x_1, x_2, \dots, x_N$ contenant N points, contenant certaines valeurs manquantes ou incohérentes, il s'agit d'ajouter des valeurs pour compléter la série




FIGURE 1.10 – Complétion de séries temporelles

Indexation

Soit X et X' deux séries temporelles, il s'agit de mesurer la similarité entre X et X' . La Résonance Magnétique Nucléaire ne peut être réalisée que si ce spin nucléaire est non nul.

Classification

Soit X une série temporelle, il s'agit de l'assigner à une des classes de séries temporelles prédéfinies.




FIGURE 1.11 – Classification de séries temporelles [6]

Partionnement

Soit X et X' deux séries temporelles d'une base de données, il s'agit de regrouper différentes partitions de X et X' .

Détection d'anomalie

Soit X une série temporelle, il s'agit de trouver les valeurs anormales de X .




FIGURE 1.12 – Détection d'anomalie de séries temporelles [7]

Dans le cadre du Bachelorarbeit, pour les différentes approches, la prédiction des séries temporelles est le domaine sur lequel nous allons nous focaliser.

1.3 Prédiction des séries temporelles

La prédiction des séries temporelles est un domaine varié contenant de nombreuses méthodes de prédiction. Le choix du modèle pour la prédiction des séries temporelles dépend de plusieurs facteurs, notamment la nature des données, la présence de tendances ou de saisons, la taille de l'ensemble de données et le contexte spécifique de la tâche. Il y a différents types de modèles de prédiction. Il y a d'un côté les modèles de prédiction basés sur les statistiques, qu'on va appeler les modèles statistiques, et de l'autre côté, les modèles utilisant le machine learning. Nous allons commencer par voir les modèles statistiques.

1.3.1 Méthodes statistiques de prédiction des séries temporelles

On peut citer quelques modèles statistiques de prédiction :

- Régression
- Moyenne mobile
- Régression auto-régressive
- Modèles ARMA et ARIMA

Nous allons aborder ces modèles plus précisément dans la suite. Nous allons commencer par voir une notion importante dans l'étude des séries temporelles. Certains modèles nécessitent que la série temporelle soit stationnaire.




FIGURE 1.13 – Illustration de la notion de stationnarité [8]

Pour qu'une série soit dite stationnaire, il faut que la moyenne, la variance et la covariance restent constantes, comme le montre la figure 13. Dans le cas du Bachelorarbeit la série n'est pas stationnaire, il va donc falloir faire attention aux modèles de prédiction utilisés.

1.3.2 Régression

Les modèles de régression peuvent être simple, on peut prédire l'évolution de certaines séries temporelles par des régressions linéaire (figure 14). Cependant d'autres régressions sont possibles comme une régression polynomiale (figure 15), ou encore exponentielle (figure 16).




FIGURE 1.14 – Régression linéaire d'une série temporelle




FIGURE 1.15 – Régression exponentielle d'une série temporelle




FIGURE 1.16 – Régression polynomiale d'une série temporelle [9]

On peut voir néanmoins que les régressions ne permettent pas de détecter certains phénomènes qui se produisent de manière répétée. On en déduit que ces modèles permettent d'accéder à la tendance de la série temporelle dans certains cas, cependant la saisonnalité de la série temporelle n'est pas prise en compte dans la prédiction de la série temporelle. De plus le bruit n'est pas pris en compte par ces méthodes de prédiction.

1.3.3 Modèle à moyenne mobile (MA)

Les modèles de moyenne mobile, souvent abrégé en modèle MA, sont un type de modèle statistique utilisé pour modéliser une série temporelle. Les modèles de moyenne mobile utilisent des termes d'erreur aléatoire passés pour prédire les valeurs futures.

$$\forall t : X_t = \varepsilon_t + \sum_{i=1}^q \alpha_i \cdot \varepsilon_{t-i} \quad (1.1)$$

En d'autres termes, le modèle de moyenne mobile prédit la valeur actuelle de la série temporelle en utilisant une combinaison linéaire des termes d'erreur aléatoire à des instants passés, avec des coefficients de moyenne mobile spécifiques. La recherche des coefficients de moyenne mobile sera détaillée plus bas. Dans la pratique, le modèle à moyenne mobile est noté comme une fonction dépendant de l'ordre q , le nombre de termes aléatoire que l'on souhaite utiliser pour prédire la valeur de la série temporelle à l'instant T . Plus q est élevé, plus le modèle prend en compte les erreurs passées pour prédire les valeurs futures. Cette méthode nécessite que la série temporelle soit stationnaire. En effet, ces méthodes ne sont généralement pas conçues pour capturer les tendances à long terme d'une série temporelle. Si la série non stationnaire présente une tendance, le modèle MA pourrait ne pas fournir une représentation adéquate de cette tendance. De plus, les modèles MA se basent sur l'idée de stationnarité, et si la série temporelle n'est pas stationnaire, le modèle peut ne pas être capable de modéliser correctement la structure temporelle de la série.

1.3.4 Modèle à régression autorégressive (AR)

Les modèles autoregressifs, souvent abrégé en modèle AR, sont un type de modèle statistique utilisé pour modéliser une série temporelle. L'idée principale derrière un modèle autoregressif est que la valeur actuelle de la série temporelle dépend linéairement de ses valeurs passées. C'est pourquoi le modèle autoregressif prédit la valeur actuelle de la série temporelle en utilisant une combinaison linéaire de ses valeurs passées, avec des coefficients autoregressifs spécifiques. La recherche des coefficients autoregressifs sera détaillée plus bas.

$$\forall t : X_t = \varepsilon_t + \sum_{i=1}^p \alpha_i \cdot X_{t-i} \quad (1.2)$$

Dans la pratique, le modèle à régression autorégressive se note comme une fonction dépendant de l'ordre p , le nombre de valeurs passées incluses dans le modèle. Plus p est élevé, plus le modèle prend en compte les valeurs passées, ce qui peut être nécessaire pour capturer des saisonnalités temporelles complexes. Cette méthode nécessite aussi que la série temporelle soit stationnaire. Cette méthode n'est pas conçue pour capturer une tendance. C'est pourquoi, en raison de la non-stationnarité de la série, les prédictions d'un modèle AR seul peuvent être peu fiables, car elles ne tiennent pas compte des tendances temporelles importantes.

Modèle ARMA

Un modèle ARMA (Autorégressive à moyenne mobile) est un modèle statistique utilisé pour modéliser les séries temporelles. Il combine deux composantes principales : l'autorégression (AR) et la moyenne mobile (MA), présentée précédemment.

$$\forall t : X_t = \varepsilon_t + \sum_{i=1}^p \alpha_i \cdot X_{t-i} + \sum_{i=1}^q \beta_i \cdot \varepsilon_{t-i} \quad (1.3)$$

Un modèle ARMA combine ces deux composantes pour créer un modèle plus flexible capable de capturer à la fois les dépendances auto-régressives et les dépendances de moyenne mobile dans la série temporelle. Un modèle ARMA(p, q) est défini par les paramètres p et q représentant respectivement l'ordre de la composante AR et de la composante MA, définie précédemment. Cependant, les modèles ARMA ne sont pas conçus pour modéliser les tendances à long terme présentes dans une série temporelle non stationnaire. Si la série temporelle contient une tendance, un modèle ARMA seul peut ne pas être capable de capturer cette tendance de manière adéquate.

1.3.5 Modèle ARIMA

Un modèle ARIMA (Autorégressive à moyenne mobile intégré) est un modèle statistique largement utilisé pour modéliser et prévoir des séries temporelles. Il combine les composantes d'autorégression (AR), de moyenne mobile (MA), tout en ajoutant une nouvelle

composante I d'intégration. Les modèles ARIMA sont particulièrement utiles pour traiter des séries temporelles qui présentent des tendances, des saisons ou d'autres structures temporelles complexes. En effet la composante I capture la non-stationnarité de la série temporelle en différenciant les observations. L'ordre d'intégration d représente le nombre de différenciations nécessaires pour rendre la série temporelle stationnaire. Un modèle ARIMA est noté $ARIMA(p, d, q)$, où :

- p est l'ordre de la composante autorégressive (AR)
- q est l'ordre de la composante à moyenne mobile (MA)
- d est l'ordre d'intégration

1.3.6 Ordre du modèle ARIMA

Pour déterminer les différents paramètres p , d , q du modèle ARIMA plusieurs méthodes peuvent être utilisées. Premièrement, pour déterminer l'ordre d , il faut différencier la série temporelle, jusqu'à retrouver une série stationnaire. En ce qui concerne l'ordre p et l'ordre q il faut utiliser certaines méthodes pour définir les différentes valeurs. Les méthodes communément utilisées sont la méthode d'autocorrélation ainsi que la méthode d'autocorrélation partielle.

Méthode d'autocorrélation

La méthode d'autocorrélation est une mesure statistique qui évalue la corrélation entre les valeurs d'une série temporelle et ses propres valeurs décalées dans le temps, qu'on appelle lag. Autrement dit, elle quantifie la similitude entre une observation à un instant T donné et les observations précédentes ou suivantes dans la série temporelle. On peut calculer la fonction d'autocorrélation, notée ACF, pour un certain décalage k .

$$ACF(k) = \frac{Cov(Y_t, Y_{t-k})}{\sqrt{Var(Y_t) \cdot Var(Y_{t-k})}} \quad (1.4)$$

On peut tracer l'évolution de la fonction d'autocorrélation comme le montre la figure 17.




FIGURE 1.17 – Exemple de fonction d'autocorrélation

Suivant les résultats obtenus, on peut déduire des valeurs des coefficients pour le modèle ARIMA(p, d, q).

	Pic important dépassant la limite de significativité sur les premiers décalages, avec une décroissance progressive	Il faut procéder au test d'autocorrélation partielle, ou nous pouvons estimer l'ordre p peut en identifiant le premier retard où l'ACF traverse le seuil de non-significativité.
	Pic important dépassant la limite de significativité sur le premier décalage, enchainant par une vague décroissante alternant entre positif et négatif	Il faut procéder au test d'autocorrélation partielle, ou nous pouvons estimer l'ordre p peut en identifiant le premier retard où l'ACF traverse le seuil de non-significativité.
	Pic significatif sur les premières valeurs de décalage, puis uniquement des valeurs ne dépassant pas la limite de significativité, sans décroissance progressive	Le nombre de corrélations significatives indique l'ordre du terme de moyenne mobile. On peut donc trouver q à l'aide de cette méthode

Méthode d'autocorrélation partielle

L'autocorrélation partielle (PACF) est une mesure statistique qui évalue la corrélation entre les valeurs d'une série temporelle à un certain retard donné et ses valeurs décalées dans le temps, tout en éliminant l'effet des retards intermédiaires. La PACF mesure alors la corrélation directe entre deux observations, tout en contrôlant pour l'influence des observations intermédiaires. Cependant cette méthode implique des covariances et des variances conditionnelles, dépassant largement le cadre du Bachelorarbeit.

1.3.7 Coefficients autorégressifs et de moyenne mobile

Comme expliqué précédemment, il est nécessaire de trouver les coefficients autorégressifs et ceux de la moyenne mobile pour mettre en place un modèle ARIMA. Pour ce faire, il existe de nombreuses méthodes permettant de trouver ces coefficients. Nous allons nous concentrer sur une méthode, l'utilisation des moindres carrés. Pour ce faire, il faut calculer en prenant des coefficients quelconques, la différence entre la valeur de la série temporelle et la valeur de la prédiction. On essaye ensuite de trouver le minimum de la somme, en jouant sur les coefficients d'autorégressifs. Pour trouver les coefficients de moyenne mobile, on procède de la même manière.

1.3.8 Machine learning

La propagation du machine learning a révolutionné notre capacité à analyser et prédire les phénomènes temporels complexes représenté par différentes séries temporelles. L'utilisation de techniques de machine learning dans la prédiction des séries temporelles offre une approche puissante et flexible pour modéliser les schémas complexes et non linéaires qui interviennent dans ces données. L'un des principaux avantages du machine learning dans ce contexte est sa capacité à extraire automatiquement des modèles à partir de données historiques issues de base de données, permettant ainsi une adaptation plus dynamique aux tendances et aux variations temporelles. Des algorithmes sophistiqués tels que les réseaux neuronaux, les machines à vecteurs de support (SVM), les arbres de décision et les méthodes ensemblistes ont été appliqués avec succès pour capturer la structure temporelle des séries, dépassant souvent les performances des méthodes traditionnelles. Nous allons voir plus en détail l'utilisation des réseaux neuronaux dans le cadre de la prédiction de série temporelle.

Réseaux neuronaux

Les réseaux neuronaux sont des modèles d'apprentissage automatique inspirés par le fonctionnement du cerveau humain. Ils sont composés de neurones artificiels organisés en couches et interconnectés par des poids. Le processus d'apprentissage des réseaux neuronaux implique l'ajustement des poids pour minimiser l'erreur entre les prédictions du modèle et les valeurs réelles. Un réseau neuronal peut être schématiser comme sur la figure 18.




FIGURE 1.18 – Schéma réseau neuronal

Sur le schéma, on peut voir une couche d'entrée, qui correspond à différentes valeurs

de la série temporelles avant la date T , et la couche de sortie correspond à une valeur pour la date $T+1$. Entre les deux, on peut voir différentes couches cachées qui sont composées de neurones artificiels. Un neurone artificiel peut être schématisé comme sur le schéma de la figure 19.




FIGURE 1.19 – Schéma d'un neurone artificiel

On voit qu'un neurone reçoit des valeurs dites d'entrée, auxquelles il affecte un poids, et les additionne tous. Si cette somme pondérée dépasse un certain seuil, on va pouvoir appliquer une fonction d'activation et transmettre la valeur résultante aux prochains neurones. Ces fonctions d'activation introduisent la non-linéarité dans les réseaux de neurones, nécessaire pour résoudre des problèmes complexes. On peut voir différentes fonctions d'activation sur la figure 20.




FIGURE 1.20 – Exemple de fonction d'activation

Les poids de chaque neurone varient le long de l'entraînement de notre modèle machine learning sur une base de données. Ces poids subissent un algorithme d'optimisation du type descente de gradient. La descente du gradient est un algorithme d'optimisation utilisé pour

minimiser une fonction afin de trouver les paramètres qui donnent la meilleure performance à un modèle. Pour ce faire, l'algorithme calcule le dérivé partiel de la fonction par rapport à chacun des paramètres, et évalue ensuite comment la fonction varie en fonction de chaque paramètre.

1.4 Choix du modèle

Après avoir vu les différents modèles de prédiction, ainsi que les deux approches possibles dans notre cas, j'ai décidé de choisir la première approche, celle qui consiste à prédire l'évolution de la série temporelle, en connaissant son évolution jusqu'à T . Pour ce faire j'ai choisi d'utiliser un modèle ARIMA. Ce modèle semble pouvoir s'adapter à nos séries temporelles, car il ajoute une composante d'intégration qui permet de rendre la série stationnaire. De plus ce modèle semble plus simple à implémenter qu'un réseau de neurones. C'est donc ce modèle que nous allons choisir dans un premier temps.

Chapitre 2

Travaux réalisés pour le Bachelorarbeit

Dans cette partie, nous allons voir les travaux réalisés pour mon Bachelorarbeit tout au long de l'année, avec les résultats obtenus, les problèmes rencontrés ainsi que les solutions qui ont été trouvés pour les différents problèmes.

2.1 Extraction des données

Pour commencer mon Bachelorarbeit, j'ai dû extraire les données issues d'expériences pour pouvoir les utiliser sur python. Durant cette phase d'extraction des données je n'ai pas rencontré de problème, cependant, j'ai réalisé à ce moment la taille des données qui m'ont été confiées.




FIGURE 2.1 – Exemple d'une série temporelle issue des expériences avec la machine de fromage

J'ai choisi de représenter en abscisse sur la figure 21 le nombre de points, pour illustrer la taille de ces séries temporelles.

2.2 Mise en place d'un modèle ARIMA

J'ai codé, dans un premier temps, un modèle ARIMA, sans me soucier de la recherche des coefficients p , d et q . Ce modèle a été testé sur des séries temporelles plus simples que celles de notre étude, et nous donne les résultats suivants :




FIGURE 2.2 – Prédiction de séries temporelles à l'aide du premier modèle ARIMA(10,2,10)

On souhaite mesurer la performance de notre prédiction, pour ce faire, nous allons utiliser des indicateurs de performances tel que MAE, MSE, RMSE ou encore R^2

- MAE (Mean Absolute Error), calcule la moyenne des écarts absolus entre les prédictions du modèle et les valeurs réelles. Cette mesure est utile car elle donne une indication de la magnitude des erreurs de prédiction, sans se soucier de leur direction.
- Le MSE (Mean Squared Error), quant à lui, calcule la moyenne des carrés des écarts entre les prédictions du modèle et les valeurs réelles. Il pénalise davantage les grosses erreurs que le MAE, car il élève les écarts au carré. Le RMSE (Root Mean Squared Error) est simplement la racine carrée du MSE, ce qui le rend plus interprétable dans les mêmes unités que la variable cible.
- Le coefficient de détermination R^2 est une mesure globale de l'adéquation du modèle aux données. Il représente la proportion de la variance de la variable dépendante qui est expliquée par le modèle. Un R^2 proche de 1 indique un ajustement parfait du modèle aux données, tandis qu'un R^2 proche de 0 indique un ajustement médiocre. Cependant, il est important de noter que le R^2 seul ne fournit pas d'informations sur la direction ou la magnitude des erreurs de prédiction.

Métrique	Ensemble d'entraînement	Ensemble de test
MAE	8.887970	23.372886
MSE	230.808916	979.291142
RMSE	15.192397	31.293628
R^2	0.968186	0.839941

TABLE 2.1 – Critère de performance pour la prédiction du premier modèle ARIMA

Cependant, lorsque l'on essaye sur les séries temporelles de notre étude, on obtient le résultat suivant :




FIGURE 2.3 – Evolution de la force de formage à l'aide du premier modèle ARIMA(10,2,10)

Pour comprendre le problème, il faut comprendre que le modèle ARIMA se base sur les valeurs précédentes de la série temporelle. Ce nombre de valeurs est conditionné par les coefficients p et d . J'ai fixé dans un premier temps p et d à 10, ce qui implique que les 10 valeurs précédentes la prédiction sont utilisés pour réaliser la prédiction. Dans notre cas, étant donnée la taille des séries temporelles qui interviennent dans notre étude, les 10 valeurs précédentes ne représentent qu'un bruit, ce qui explique pourquoi le modèle ARIMA ne fonctionne pas.

2.3 Echantillonnage des séries temporelles de notre étude

2.3.1 Méthode d'échantillonnage

Nous avons vu que la taille des séries temporelles est trop importante pour pouvoir utiliser notre modèle ARIMA. On doit donc échantillonner les séries, pour faire écho à l'état de l'art, il faut segmenter les séries temporelles. Pour ce faire, j'ai choisi 2 méthodes, et j'ai cherché à trouver laquelle est la plus efficace.

La première méthode consiste à prélever des points de la série temporelle de manière équidistante. On obtient le résultat suivant :




FIGURE 2.4 – Echantillonnage avec la méthode des points équidistants

La deuxième méthode consiste à diviser la série temporelle en segment et de faire la moyenne de la série temporelle sur ces segments. On remplace ensuite le segment par la valeur de la moyenne calculée. On obtient le résultat suivant :




FIGURE 2.5 – Echantillonnage avec la méthode le la moyenne des segments

2.3.2 Verification de la méthode d'échantillonnage

Dans un second temps, j'ai voulu vérifier la validité de mon échantillonnage, et d'estimer les erreurs induites dans la série temporelle. Pour ce faire, j'ai codé un algorithme permettant de mesurer l'erreur introduite par l'échantillonnage. Cet algorithme calcule la différence entre la série temporelle et la série échantillonnée, en utilisant une interpolation linéaire pour les valeurs entre deux différents instants de la série échantillonnée. On obtient les résultats suivant :

Méthode	Distance
Points équidistant	505.18522176
Moyenne des segments	393.71895355

TABLE 2.2 – Distance moyenne des différentes méthodes d'échantillonnages

On gardera donc la méthode de la moyenne des segments pour effectuer nos échantillonnages

2.4 Prédiction des séries temporelles échantillonnées

2.4.1 Modèle ARIMA avec des hyperparamètres quelconques

Maintenant que nous avons échantillonnées nos séries temporelles, nous pouvons repasser à notre premier modèle ARIMA. Le résultat de l'utilisation de ce modèle sur une série temporelle échantillonnée est le suivant :




FIGURE 2.6 – Prédiction du modèle ARIMA(10,2,10) sur une série échantillonnée

Métrique	Ensemble d'entraînement	Ensemble de test
MAE	4.548889	34.310647
MSE	193.888215	2752.681923
RMSE	13.924375	52.466007
R^2	0.987310	0.219954

TABLE 2.3 – Critère de performance pour la prédiction de série échantillonnée

On peut voir que le modèle ARIMA fonctionne désormais, mais ne nous donne pas des résultats très précis. Cependant, en jouant sur les paramètres p , d , q , on peut obtenir de meilleurs résultats :




FIGURE 2.7 – Prédiction du modèle ARIMA(20,2,20) sur une série échantillonnée

Métrique	Ensemble d'entraînement	Ensemble de test
MAE	4.517625	23.200039
MSE	192.640163	803.521920
RMSE	13.879487	28.346462
R^2	0.987392	0.772301

TABLE 2.4 – Critère de performance pour la prédiction de série échantillonnée avec différents hyperparamètres

On remarque que tout les critères de performances sont mieux pour le modèle ARIMA(20,2,20), il suffit donc de trouver les paramètres p , d et q optimaux, pour avoir une prédiction précise.

2.4.2 Recherche des hyperparamètres optimaux pour le modèle ARIMA

Nous avons vu dans l'état de l'art, que pour avoir des résultats optimaux avec le modèle ARIMA, la série temporelle que nous souhaitons étudier doit se rapprocher d'une série temporelle stationnaire. Le coefficient d correspond au nombre de différenciations nécessaires pour rendre la série plus stationnaire possible. On peut tracer l'évolution de la moyenne mobile et de l'écart-type mobile :




FIGURE 2.8 – Evolution de la moyenne mobile et de l'écart type mobile

On souhaite rendre la moyenne mobile et l'écart type mobile plus stationnaire. On différencie donc la série temporelle.




FIGURE 2.9 – Evolution de la moyenne et de l'écart type mobile pour une série différenciée 1 fois




FIGURE 2.10 – Evolution de la moyenne et de l'écart type mobile pour une série différenciée 2 fois

On remarque donc que à l'ordre 2 de différenciation, la moyenne mobile est quasi stationnaire, cependant, l'écart type mobile n'est pas stationnaire, on aura donc des résultats moins précis.

Pour ce qui est des paramètres p et q , j'ai codé un algorithme de recherche des hyperparamètres, nommé le Box Grid Search Algorithm. Le Box Grid Search Algorithm est une méthode d'optimisation des paramètres utilisée en apprentissage automatique. Elle consiste à définir une grille de valeurs pour chaque hyperparamètre du modèle, dans notre cas p et q . Ensuite, le modèle est entraîné et évalué pour chaque combinaison possible de valeurs d'hyperparamètres dans cette grille. Cette évaluation se fait généralement en utilisant un ensemble de données de validation. Une fois toutes les combinaisons testées, le modèle avec les meilleures performances est sélectionné comme le modèle final. Cette méthode est simple à mettre en œuvre, mais elle peut devenir coûteuse en termes de calcul lorsque la grille des hyperparamètres est grande. J'ai donc introduit une phase de validation dans la série temporelle, et j'ai utilisé l'algorithme. Cependant, comme dit précédemment, le calcul est très long, donc j'ai limité la recherche des paramètres optimaux à l'intervalle $\llbracket 10; 15 \rrbracket$ dans un premier temps. On obtient que les paramètres optimaux sont $(p,d,q)=(12,2,15)$ On trouve donc l'évolution suivante :




FIGURE 2.11 – Modèle ARIMA(12,2,15)

On remarque que la prédiction n'est toujours pas bonne, même moins bien que celle qu'on a choisi au hasard. On peut expliquer ça par le fait que l'algorithme trouve les hyperparamètres optimaux pour la phase de validation. Ces hyperparamètres ne sont pas optimaux pour la suite de la prédiction, seulement pour la phase de validation.

2.5 Mise en place d'un modèle à moyenne pondérée

Nous disposons d'un ensemble de séries temporelles qui peuvent nous servir de base de données. Pour ce faire on décompose l'ensemble de séries temporelles en un ensemble qui servira de base de données, et un autre ensemble qui servira de base de test. On peut afficher l'ensemble des séries temporelles de la base de données sur un même graphique :




FIGURE 2.12 – Ensemble des séries temporelles de la base de donnée

Nous pouvons désormais normaliser les séries temporelles, pour les représenter toutes sur un même intervalle :




FIGURE 2.13 – Ensemble des séries temporelles normalisées de la base de donnée

L'idée va être de prendre le début d'une série temporelle, et lorsqu'on arrive à la fin de la phase de validation, nous allons utiliser une moyenne pondérée de toutes les séries temporelles de la base de données, pour pouvoir faire correspondre le dernier point de la série temporelle avec le premier de la nouvelle série issue de la moyenne pondérée. Les coefficients de la moyenne sont déterminés pour faire correspondre les deux points évoqués précédemment. Avec cette méthode, on obtient les résultats suivants :




FIGURE 2.14 – Prédiction de série temporelle avec la méthode de la moyenne pondérée




FIGURE 2.15 – Prédiction de série temporelle avec la méthode de la moyenne pondérée

L'objectif maintenant va être de dénormaliser la prédiction. Pour ce faire, il faut connaître $t_{\max}$, la durée de la simulation. On aurait pu essayer de la deviner en connaissant $f_{\max}$, cependant, il n'y a pas de lien entre $f_{\max}$ et $t_{\max}$.




FIGURE 2.16 – Prédiction de série temporelle normalisée connaissant sa valeur jusqu'à T




FIGURE 2.17 – Prédiction de série temporelle comparée à la série temporelle réelle

On peut voir que l'ensemble d'entraînement et la prédiction se croise en un unique point, c'est le point qui est utilisé pour déterminer les coefficients mentionnés précédemment. L'ensemble de validation sert lui à calculer les indicateurs de performances.

Métrique	Ensemble de validation
MAE	30.389169
MSE	1223.925419
RMSE	34.984645
R^2	0.784124

TABLE 2.5 – Critère de performance pour la prédiction de série avec la méthode de la moyenne pondérée

2.5.1 Conclusion

Pour conclure ce Bachelorarbeit, nous avons du abandonner le modèle ARIMA pour la prédiction de nos séries temporelles. Ce modèle se basant sur les anciens points, il n'y aucun moyen pour le modèle de deviner que la série temporelle décroît à partir d'un moment. Je suis donc passé à une méthode plus rudimentaire, qui est effective, une moyenne pondérée. Cette méthode nous permet de prédire les séries temporelles de notre étude. Cependant il faut connaître $t_{\max}$, la durée de la simulation, car la prédiction fonctionne sur données normalisées.

Comme ouverture, nous pouvons envisager d'implémenter une méthode de prédiction qui se baserait sur la seconde approche, celle qui prédit une série temporelle à l'aide d'une base de données. On pourrait aussi imaginer l'implémentation d'un réseau de neurones, soit pour prédire uniquement $t_{\max}$ et se baser sur la méthode de la moyenne pondérée, ou encore de prédire l'ensemble de la série temporelle.

Références :

1. Badreddine Saidi. Etude expérimentale et numérique du procédé de formage incrémental à chaud de tôles en titane. Matériaux et structures en mécanique. Université de Technologie de Troyes ; École nationale d'ingénieurs de Tunis (Tunisie), 2018. Français.
2. Ali Yazid Ziat. Apprentissage de représentation pour la prédiction et la classification de séries temporelles. Réseau de neurones. Université Pierre et Marie Curie - Paris VI, 2017. Français.
3. Jérémy Belchior. Développement d'une approche couplée matériau / structure machine : application au formage incrémental robotisé. Autre. INSA de Rennes, 2013. Français.
4. Tudor Balan, Sandra Chevret, Wahb Zouhri, Daniel Boehm. Implémentation d'une méthode de Forecasting à partir de données temporelle 2023. Français en formage incrémental robotisé
5. Analysez et modelisez les séries temporelles. [Openclassrooms](#), Français
6. Michael Franklin Mbouopda, Engelbert Mephu Nguifo. Classification des Séries Temporelles Incertaines Par Transformation "Shapelet". Conférence Nationale en Intelligence Artificielle, Jun 2020, Angers, France.
7. Détection d'anomalies de séries temporelles [Quantmetry](#)
8. What is Stationarity in Time Series, Sandhya Krishnan, [CodeX](#)
9. [Documentation Azure Data Explorer](#)
10. Schéma d'un réseau neurones, Réseau de neurones artificiels : qu'est-ce que c'est et à quoi ça sert ? [Wordpress](#)
11. Schéma d'un neurone artificiel, [Researchgate](#)
12. Schéma des différentes fonctions d'activation, Shruti Jadon, [Medium](#)
13. Youssef Hmamouche. Prédiction des Séries Temporelles Larges. Algorithme et structure de données. AMU - Aix Marseille Université, 2018. Français.
14. Didier Delignières. Analyse des séries temporelles. Septembre 2007. Français.
15. Philippe Martin. Réseaux de neurones artificiels : application à la reconnaissance optique de partitions musicales. Modélisation et simulation. Université Joseph-Fourier - Grenoble I, 1992. Français.

Attestation d'authenticité

Je soussigné Alexandre SIGIRIDIS-SCHLEPP, élève-ingénieur du cursus Arts et Métiers / KIT, atteste que ce travail est personnel, cite en référence toutes les sources utilisées et ne comporte pas de plagiat.

Ich versichere wahrheitsgemäß, die Arbeit selbstständig verfasst, alle benutzten Hilfsmittel vollständig und genau angegeben und alles kenntlich gemacht zu haben, was aus Arbeiten anderer unverändert oder mit Abänderungen entnommen wurde sowie die Satzung des KIT und der Arts et Métiers zur Sicherung guter wissenschaftlicher Praxis in der jeweils gültigen Fassung beachtet zu haben.

Le 27/05/2024

